Klasifikacija teksta

Jelena Jovanovic

Klasifikacija: podsećanje

Klasifikacija: podsećanje

Za klasifikaciju su nam potrebni:

- Izlazna varijabla koja predstavlja moguće kategorije u koje instance treba razvrstati
- Atributi kojima opisujemo instance i koji su značajni za predviđanje izlazne varijable

Klasifikacija: jednostavan primer

Zadatak: predvideti da li će polaznik nekog online kursa uspešno završiti kurs

Klasifikacija: jednostavan primer

Zadatak: predvideti da li će polaznik nekog online kursa uspešno završiti kurs

Izlazna varijabla: Kurs uspešno / neuspešno završen

Klasifikacija: jednostavan primer

Zadatak: predvideti da li će polaznik nekog online kursa uspešno završiti kurs

Izlazna varijabla: Kurs uspešno / neuspešno završen

Atributi:

- procenat odgledanih video lekcija,
- procenat (tačno / netačno) urađenih domaćih zadataka,
- broj poruka poslatih u diskusionom forumu kursa,
- ...

Klasifikacija teksta: tipični zadaci

- Analiza sentimenta
- Detekcija emocija u tekstu
- Detekcija spam poruka
- Tematsko razvrstavanje teksta
- Detektovanje govora mržnje
- ...

Klasifikacija teksta: ključni elementi

I ovde je potrebno da identifikujemo ključne elemente za klasifikaciju:

- Izlazna varijabla
- Ulazne varijable (atributi)

Klasifikacija teksta: ključni elementi

I ovde je potrebno da identifikujemo ključne elemente za klasifikaciju:

- Izlazna varijabla: jednostavno, određeno samim zadatkom
- Ulazne varijable (atributi)

Klasifikacija teksta: ključni elementi

I ovde je potrebno da identifikujemo ključne elemente za klasifikaciju:

- Izlazna varijabla: jednostavno, određeno samim zadatkom
- Ulazne varijable (atributi): najčešće zahtevno; potrebno je
  - dobro upoznavanje sa tekstom koji je u fokusu zadatka
  - promišljanje teksta u kontekstu specifičnog zadatka klasifikacije

Klasifikacija teksta: atributi

Primeri često korišćenih atributa:

- dužina teksta
- metrike koje ukazuju na kohezivnost teksta
- metrike koje ukazuju na čitljivost teksta
- broj znakova interpunkcije u tekstu (npr. u slučaju detekcija spam poruka)
- ...

Klasifikacija teksta: reči kao atributi

Posebno značajna kategorija atributa:

- reči iz teksta koje su “značajne” za dati tekst i zadatak klasifikacije

Klasifikacija teksta: selekcija reči za atribute

Pitanja koja se nameću:

- Kako izdvojiti reči koje su *potencijalno značajne* za dati tekst?
- Kako proceniti *koliko su značajne* reči koje smo izdvojili, tj. kako da kvantifikujemo njihovu značajnost za dati tekst?

Klasifikacija teksta: selekcija reči za atribute

Selekcija reči je značajna iz dva razloga:

- Obezbeđuje ML algoritmu podatke koji nose “signal”
- Omogućuje redukciju dimenzionalnosti modela, a time i sklonost ka *overfitting*-u

Klasifikacija teksta: selekcija reči za atribute

Korak 1: Izdvajanje potencijalno značajnih reči, u fazi pretprocesiranja teksta:

Klasifikacija teksta: selekcija reči za atribute

Korak 1: Izdvajanje potencijalno značajnih reči, u fazi pretprocesiranja teksta:

- reči koje “površinski” deluju različito, a u osnovi imaju istu semantiku, svodimo na isti oblik (spuštanje teksta na mala slova, lematizacija)

Klasifikacija teksta: selekcija reči za atribute

Korak 1: Izdvajanje potencijalno značajnih reči, u fazi pretprocesiranja teksta:

- reči koje “površinski” deluju različito, a u osnovi imaju istu semantiku, svodimo na isti oblik (spuštanje teksta na mala slova, lematizacija)
- otklanjamo reči koje same po sebi ne nose značenje (stop words)

Klasifikacija teksta: selekcija reči za atribute

Korak 1: Izdvajanje potencijalno značajnih reči, u fazi pretprocesiranja teksta:

- reči koje “površinski” deluju različito, a u osnovi imaju istu semantiku, svodimo na isti oblik (spuštanje teksta na mala slova, lematizacija)
- otklanjamo reči koje same po sebi ne nose značenje (stop words),
- otklanjamo reči koje imaju malu šansu da se jave u tekstu sa kojim će naš klasifikator raditi (što im umanjuje značaj) - npr., URLs, brojevi, lična imena,...

Klasifikacija teksta: selekcija reči za atribute

Korak 2: Primena nekog od pristupa / modela za kvantifikovanje značajnosti reči u tekstu

- Term frequency (TF)
- Inverse Document Frequency (IDF)
- TF-IDF

Bag of Words (BoW)

Bag-of-Words (BoW)

Osnovna ideja: što se reč više pojavljuje u dokumentu, to je ona značajnija za taj dokument

=>

Mera značajnosti: učestanost pojavljivanja reči (Term Frequency - TF)

BoW: Document-term matrica

	about	bird	heard	is	the	word	you
About the bird, the bird, bird bird bird	1	5	0	0	2	0	0
You heard about the bird	1	1	1	0	1	0	1
The bird is the word	0	1	0	1	2	1	0

Slika preuzeta sa: https://vitalflux.com/text-classification-bag-of-words-model-python-sklearn/

BoW: Prednosti

Veoma jednostavan model

Često je vrlo uspešan uprkos nerealnim pretpostavkama

BoW: Nedostaci

Nerealne pretpostavke kao glavni nedostaci modela:

- Redosled reči u tekstu nije bitan
- Razmatra samo pojedinačne reči (ne i sekvence reči)
- Učestanost zajedničkog pojavljivanja reči nije bitna
- Frekventne reči nisu uvek i najznajčajnije
- ...