Klasifikacija teksta

Jelena Jovanovic

BoW: Nedostaci

Nerealne pretpostavke kao glavni nedostaci modela:

- Redosled reči u tekstu nije bitan
- Razmatra samo pojedinačne reči (ne i sekvence reči)
- Učestanost zajedničkog pojavljivanja reči nije bitna
- Frekventne reči nisu uvek i najznajčajnije
- ...

Vector Space Model (VSM)

Vector Space Model (VSM)

Unapređenje BoW modela:

- Posmatra termine (tj sekvence od 1 ili više reči), ne samo pojedinačne reči
- Uvodi različite načine za procenu značajnosti termina u tekstu

Napomena: često korišćen sinonim za “termin” u stručnoj literaturi je “**ngram**”

VSM: TF-IDF

Najčešće korišćena metrika za procenu značajnosti termina u tekstu:

TF - IDF = Term Frequency - Inverse Document Frequency

koja uzima u obzir i učestalost i neuobičajenost reči

VSM: TF-IDF

Različiti načini računanja TF-IDF

U sklearn `TfIdfVectoriser` klasi:

`tf-idf(t, d) = tf(t, d) * idf(t)`

`idf(t) = log ( n / df(t) ) + 1`

`n` - broj dokumenata

`df(t)` - broj dokumenata u kojima se termin t pojavljuje

Napomena: TF se obično normalizuje brojem reči u dokumentu

VSM: Document-term matrica

Term / Document	information technology	information system	communication technology	software application	telecommunication	computer science
1	0.77	0.55	0.45	0.13	0.14	0.15
2	0	0	0.13	0.53	0.15	0.75

Slika preuzeta sa: https://www.researchgate.net/figure/Some-Part-of-TF-IDF-Term-Document-Matrix_tbl1_306358542

VSM i sličnost dokumenata

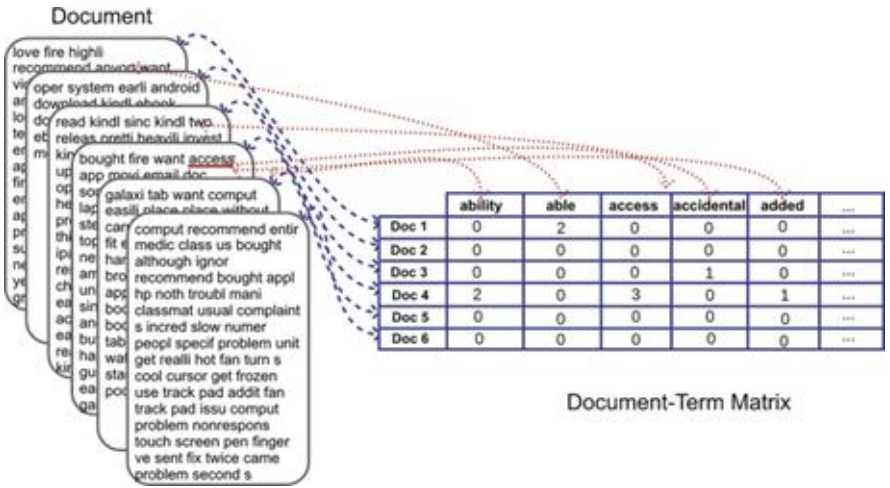
VSM omogućuje jednostavno merenje sličnosti dokumenata

Značajno za zadatke klasterizacije, neke klasifikacione algoritme, algoritme preporuke....

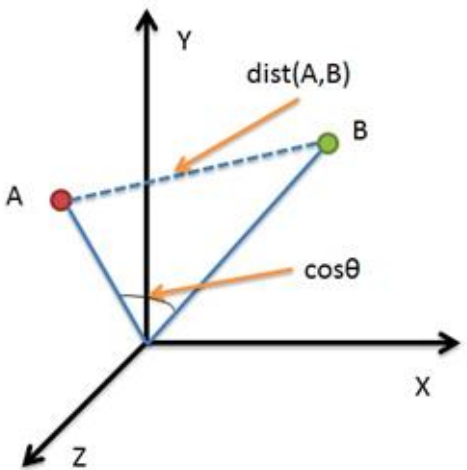
VSM i sličnost dokumenata

Dokumenti su predstavljeni kao vektori => sličnost dokumenata ≈ “blizina” njima odgovarajućih vektora

Blizina vektora se može kvantifikovati kao kosinus ugla koji vektori zaklapaju

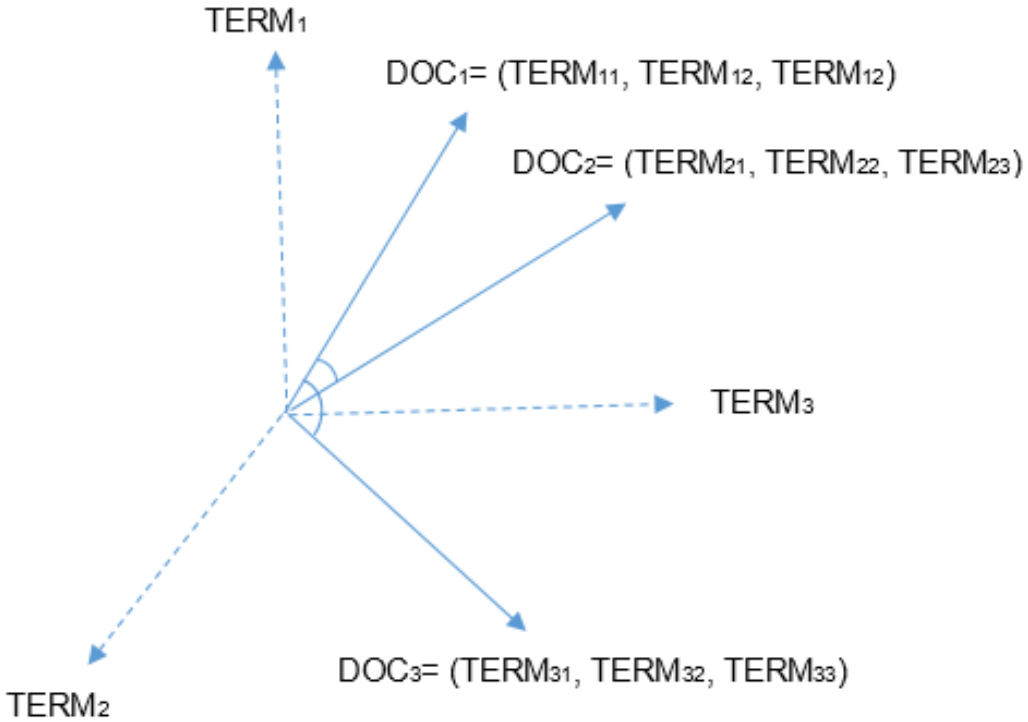


	ability	able	access	accidental	added	...
Doc 1	0	2	0	0	0	...
Doc 2	0	0	0	0	0	...
Doc 3	0	0	0	1	0	...
Doc 4	2	0	3	0	1	...
Doc 5	0	0	0	0	0	...
Doc 6	0	0	0	0	0	...



Izvori slika: https://stackoverflow.com/questions/40716459/choice-between-an-adjusted-cosine-similarity-vs-regular-cosine-similarity; https://media.springernature.com/lw685/springer-static/image/chp%3A10.1007%2F978-3-032-08086-8_4/MediaObjects/479573_1_En_4_Fig3_HTML.png

VSM i sličnost dokumenata



Izvor slike: https://www.researchgate.net/figure/Presentation-vector-space-model_fig1_303823280

VSM: Nedostatci

Vrlo ograničeno modelovanje redosleda reči u rečenici
- svedeno na nizove od po 2 do 3 reči (bigrami, trigrami)

Vrlo ograničeno korišćenje (empirijski potvrđene) povezanosti među rečima, tj. verovatnoće zajedničkog pojavljivanja reči

Ne uzima uopšte u obzir značenje reči i semantičku sličnost / povezanost reči

Vodi kreiranju veoma velikih a slabo popunjenih (sparse) vektorskih reprezentacija dokumenata, koje su nezgodne za dalja računanja