Klasifikacija teksta

Jelena Jovanovic

Word Embeddings

Vektori reči (Word Embeddings)

Pristup modelovanju teksta gde se svaka reč predstavlja višedimenzionalnim vektorom koji bi trebalo da enkodira što je moguće više značenja (semantike) reči

Vektori reči (Word Embeddings)

Pristup modelovanju teksta gde se svaka reč predstavlja višedimenzionalnim vektorom koji bi trebalo da enkodira što je moguće više značenja (semantike) reči

Osnovna ideja je sadržana u rečima britanskog lingviste John Rupert Firth-a:

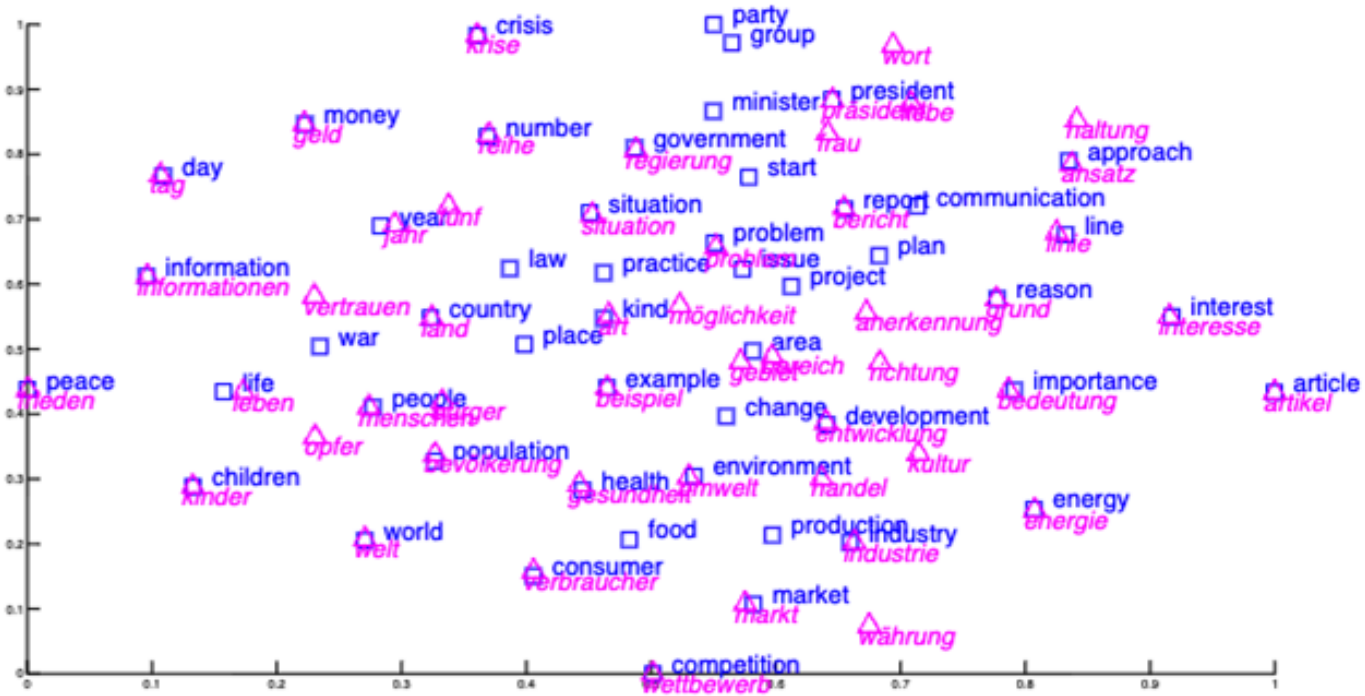
> *"You shall know a word by the company it keeps"*

Drugim rečima, značenje reči je u velikoj meri određeno rečima u "okruženju", odnosno, rečima sa kojima se data reč često zajedno pojavljuje

Vektori reči

Reči su predstavljene *gusto popunjenim vektorima* (dense vectors) u visokodimenioznalnom, kontinualnom vektorskom prostoru,
u kome se *semantički srodne reči* nalaze *jedna blizu druge*

Vektori reči



Izvor slike: https://nlp.stanford.edu/~lmthang/data/papers/naacl15_bivec.pdf

Vektori reči u zadacima analogije

Man is to Woman as King is to _____

King - Man + Woman = _____

Paris is to France as Madrid is to _____

Madrid - Paris + France = _____

Kako nastaju Vektori reči?

Nastaju kao “nusprodukt” obučavanja neuronske mreže da predvidi reč na osnovu reči koje čine njen kontekst

Primer koji sledi to ilustruje u kontekstu **Word2Vec**, jednog od prvih i najpoznatijih pristupa za kreiranje vektorskih reprezentacija reči

Izvor primera: https://lilianweng.github.io/posts/2017-10-15-word-embedding/

Kreiranje vektora reči: Word2Vec primer

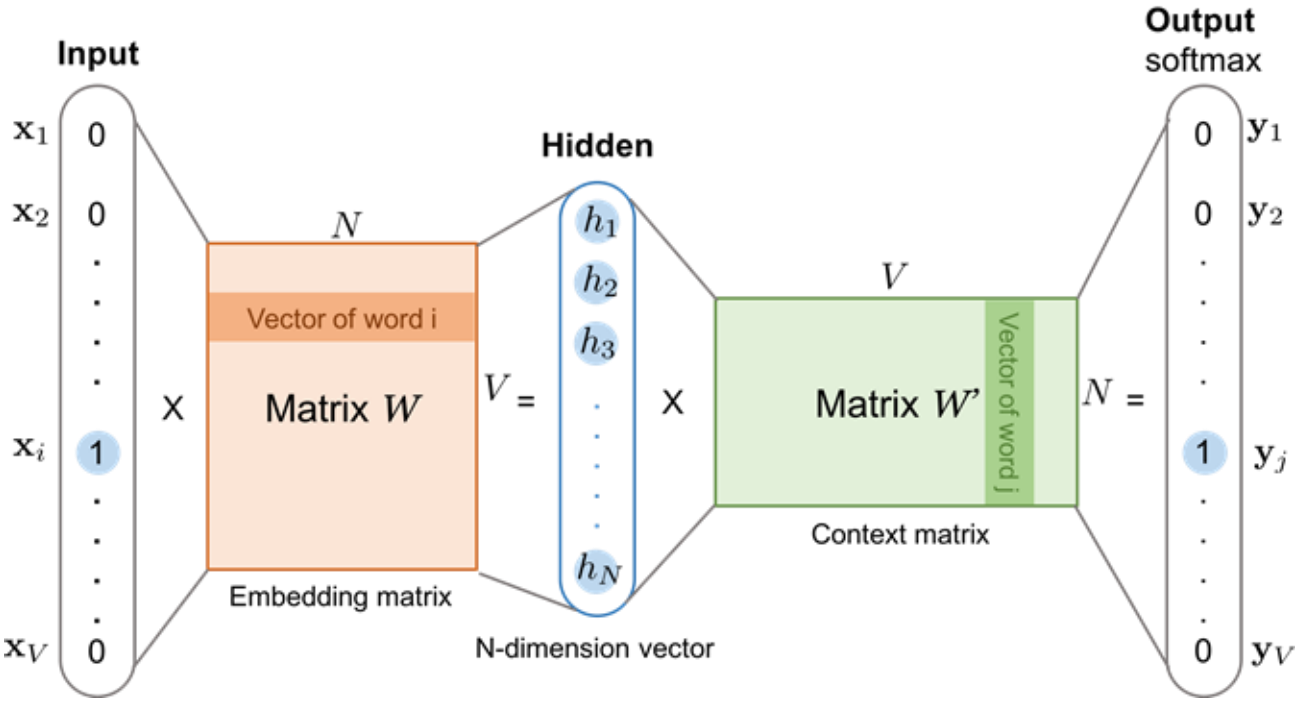
Korak 1: Kreiranje trening seta

> "The man who passes the sentence should swing the sword." – Ned Stark

Sliding window (size = 5)	Target word	Context
[The man who]	the	man, who
[The man who passes]	man	the, who, passes
[The man who passes the]	who	the, man, passes, the
[man who passes the sentence]	passes	man, who, the, sentence
...	...	...
[sentence should swing the sword]	swing	sentence, should, the, sword
[should swing the sword]	the	should, swing, sword
[swing the sword]	sword	swing, the

Kreiranje vektora reči: Word2Vec primer

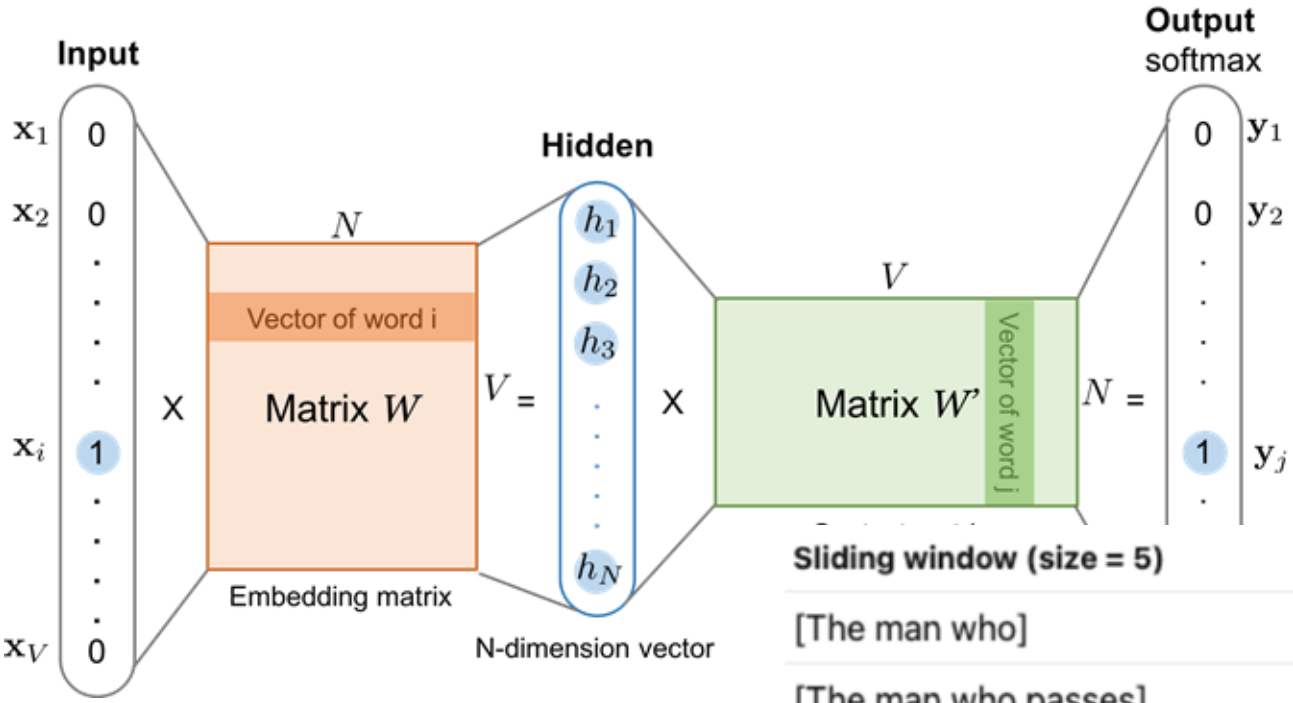
Korak 2: Trening modela, Skip-Gram



Skip Gram model na osnovu reči na ulazu (target) predviđa koja reč čini njen kontekst

Kreiranje vektora reči: Word2Vec primer

Korak 2: Trening modela, Skip-Gram

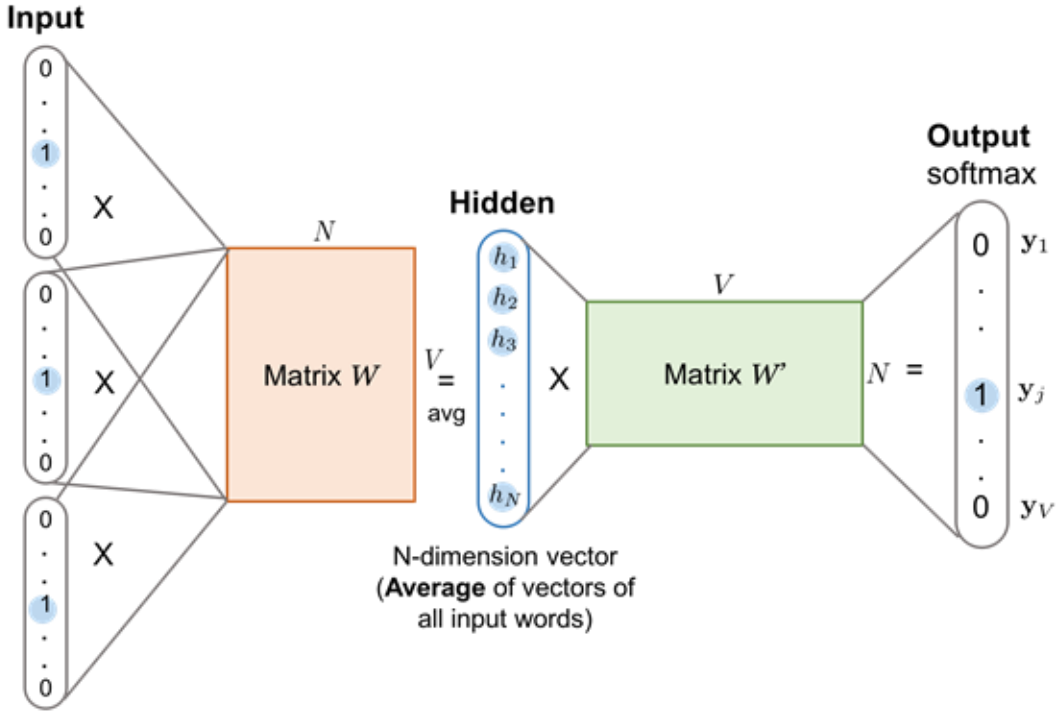


Trening set (target word, context word)
Npr.
(man, the),
(man, who),
(man, passes),
...

Sliding window (size = 5)	Target word	Context
[The man who]	the	man, who
[The man who passes]	man	the, who, passes

Kreiranje vektora reči: Word2Vec primer

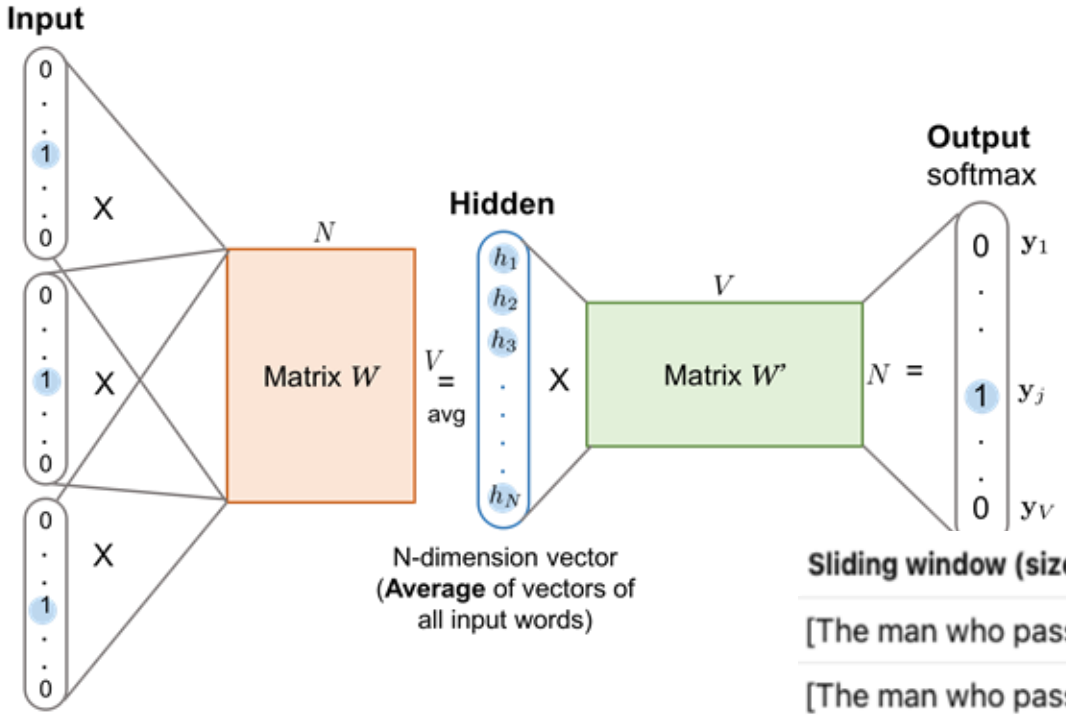
Korak 2: Trening modela, Continuous Bag of Words (CBoW)



CBoW model na osnovu konteksta (tj više reči koje čine kontekst) predviđa reč koja pripada tom kontekstu (target)

Kreiranje vektora reči: Word2Vec primer

Korak 2: Trening modela, Continuous Bag of Words (CBoW)



Trening set (context words, target word)
Npr.
(man, who, the),
(the, who, passes, man),
...

Sliding window (size = 5)	Target word	Context
[The man who passes]	man	the, who, passes
[The man who passes the]	who	the, man, passes, the

Poznati pristupi za kreiranje vektora reči

Word2Vec: https://code.google.com/archive/p/word2vec/

GloVe: http://nlp.stanford.edu/projects/glove/

ConceptNet Numberbatch: https://github.com/commonsense/conceptnet-numberbatch

FastText: https://fasttext.cc/docs/en/english-vectors.html

Preporuka

Predavanje Jay Alammar-a, “Intuition & Use-Cases of Embeddings in NLP & beyond”: https://www.youtube.com/watch?v=4-QoMdSqG_I

Kao i njegov blog post The Illustrated Word2vec koji je postao globalno poznat kao najbolje objašnjenje embedding koncepta i posebno Word2Vec modela

Primena treniranih vektora reči u klasifikaciji teksta

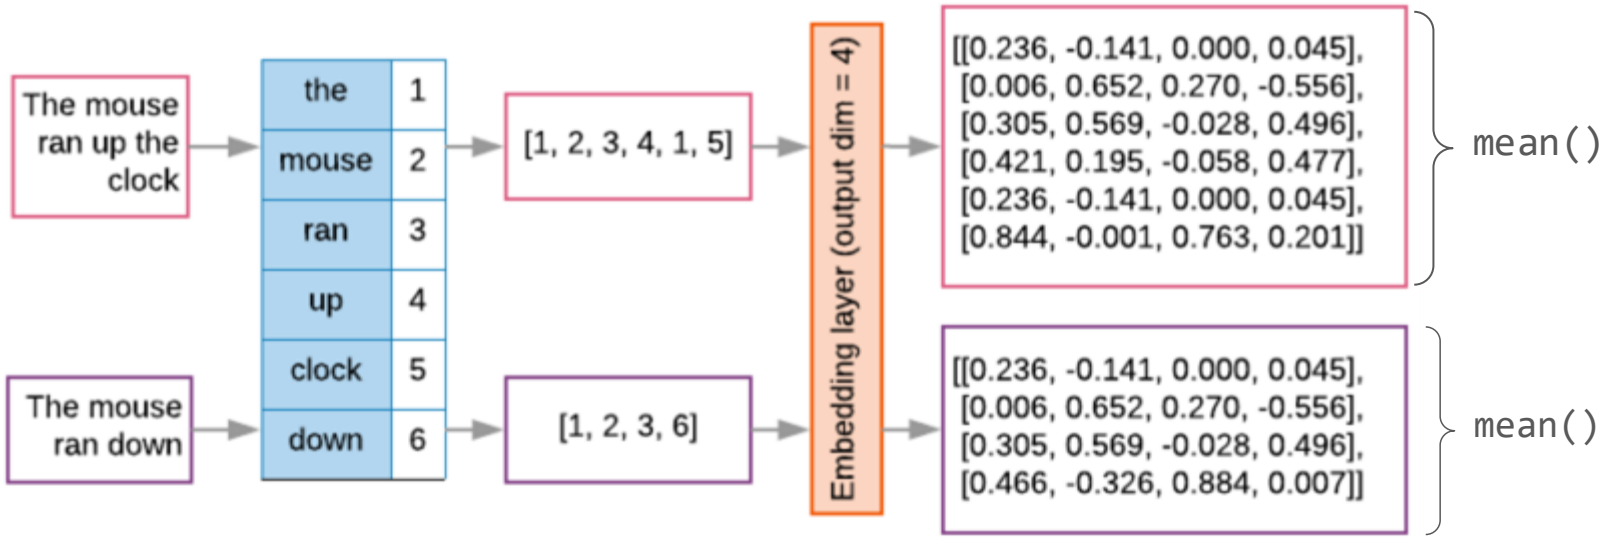
Jednostavni pristupi za kreiranje numeričke reprezentacije dokumenata:

- Kreirati vektor dokumenta kao prosek vektora reči koji čine dokument

Primena treniranih vektora reči u klasifikaciji teksta

Jednostavni pristupi za kreiranje numeričke reprezentacije dokumenata:

- Kreirati vektor dokumenta kao prosek vektora reči koji čine dokument



Izvor slike: https://towardsdatascience.com/pre-trained-word-embedding-for-text-classification-end2end-approach-5fbf5cd8aead/

Primena treniranih vektora reči u klasifikaciji teksta

Jednostavni pristupi za kreiranje numeričke reprezentacije dokumenata:

- Kreirati vektor dokumenta kao prosek vektora reči koji čine dokument
- Kreirati vektor dokumenta kao prosek otežanih vektora reči koji čine dokument
  - Kao težinski faktor obično se koristi TF ili TF-IDF reči u datom dokumentu i tim faktorom se množi vektor reči pre uprosečavanja