SMOTE

Synthetic Minority Oversampling Technique

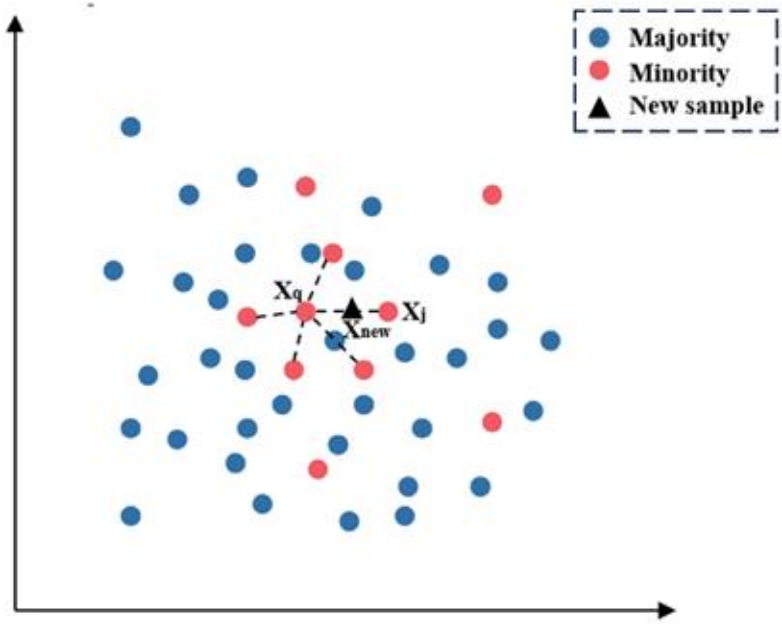
SMOTE

Tehnika uzorkovanja (oversampling) dizajnirana da generiše sintetičke instance manjinske klase kako bi se uravnotežio skup podataka

Ne duplira samo postojeće instance manjinske klase (što bi moglo dovesti do overfitting-a), već, kreira nove instance, slične postojećim

SMOTE postupak

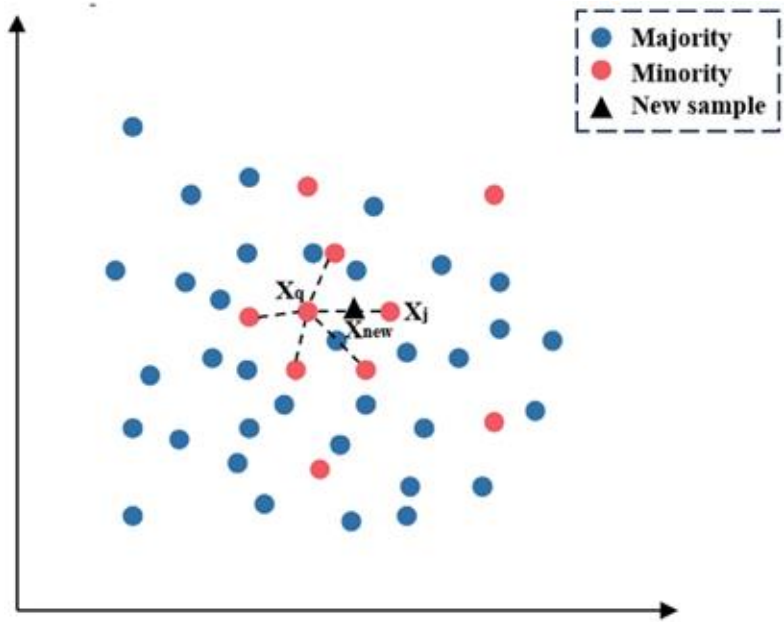
1. Nasumično se uzima jedan uzorak (instanca) manjinske klase
2. Pronalazi se k najbližih suseda izabrane instance koji takođe pripadaju manjinskoj klasi
3. Nasumično se bira jedan od k suseda
4. Generiše se nova instanca, duž “linije” koja povezuje originalnu instancu i odabranog suseda



Izvor slike: https://www.nature.com/articles/s41598-025-09506-w

SMOTE postupak

1. Nasumično se uzima jedan uzorak (instanca) manjinske klase
2. Pronalazi se k najbližih suseda izabrane instance koji takođe pripadaju manjinskoj klasi
3. Nasumično se bira jedan od k suseda
4. Generiše se nova instanca, duž “linije” koja povezuje originalnu instancu i odabranog suseda
5. Koraci 1-4 se ponavljaju sve dok manjinska klasa ne bude uravnotežena sa većinskom klasom



Izvor slike: https://www.nature.com/articles/s41598-025-09506-w

SMOTE: Generisanje nove instance

$$x_{new} = x_i + (x_s - x_i) * \delta$$

Gde su:

- X_{new} - nova instanca, generisana u SMOTE postupku
- Xi - originalna instanca manjinske klase
- Xs - slučajno izabran najbliži sused originalne instance
- δ - nasumično izabran broj između 0 i 1