Vežba: zadatak klasifikacije teksta (TF-IDF, logistička regresija i ColumnTransformer)

U fajlu “Womens Clothing E-Commerce Reviews.csv”[1] su dati podaci o komentarima kupaca jedne internet prodavnice ženske odeće. Svaki red je jedan komentar na jedan proizvod. Fajl sadrži sledeće kolone (varijable):

- *Clothing ID* - identifikator proizvoda na koji se komentar odnosi
- *Age* - starost kupca koji je ostavio komentar
- *Title* - naslov komentara (nije obavezan, pa ponekad nedostaje)
- *Review Text* - tekst komentara kupca
- *Rating* - ocena proizvoda od 1 do 5 koju je kupac dao
- *Recommended IND* - 1 ako kupac preporučuje proizvod, 0 ako ne preporučuje
- *Positive Feedback Count* - broj drugih kupaca kojima je komentar bio koristan
- *Division Name* - divizija proizvoda (npr. General, Intimates)
- *Department Name* - odeljenje proizvoda (npr. Tops, Dresses, Bottoms)
- *Class Name* - klasa proizvoda (npr. Knits, Blouses, Jeans)

Prva kolona u fajlu nema ime i predstavlja redni broj reda; nju ne koristiti. Zbog vremena izvršavanja, sve korake raditi nad slučajnim uzorkom od 5000 komentara (`random_state=1`).

Koristeći opisane podatke iz navedenog fajla, potrebno je uraditi sledeće:

- Učitati podatke i ispitati ih (tipovi kolona, nedostajuće vrednosti). Izbaciti komentare kod kojih nedostaje *Review Text*. Kreirati novu kolonu *review_content* koja objedinjuje sadržaj kolona *Title* i *Review Text* (kroz obično nadovezivanje stringova). Voditi računa da nedostajući naslov ne sme da “pokvari” spojeni tekst.
- Polazeći od kolone *Rating* napraviti novu *sentiment* varijablu sa tri moguće vrednosti (negativan, neutralan, pozitivan) primenjujući sledeće mapiranje:
  - rating 1 i 2 se mapiraju u “negativan” sentiment,
  - rating 3 se mapira u “neutralan” sentiment,
  - rating 4 i 5 se mapiraju u “pozitivan” sentiment.

  Varijabla *sentiment* bi trebalo da posluži kao izlazna varijabla za klasifikaciju u ovom zadatku. Prikazati koliki je udeo svake klase i ukratko prokomentarisati šta to znači za kasniju evaluaciju.
- Proceniti da li bi još neku od varijabli iz polaznog dataset-a trebalo primeniti za kreiranje modela. Za svaku kolonu osim *review_content* ukratko obrazložiti odluku (uključiti / ne uključiti). Za numeričke kolone odluku potkrepiti grafikom raspodele po klasama sentimenta, a za kategorijske brojem različitih vrednosti i raspodelom

po klasama. Posebno razmotriti da li je upotreba kolone *Recommended IND* opravdana u odnosu na to šta se predviđa. **Model mora da koristi bar jednu numeričku i bar jednu kategorijsku kolonu** pored teksta.

- Transformisati kolonu *review_content* u numerički oblik primenom Vector Space Modela i konkretno TF-IDF metrike. Pre računanja TF-IDF vrednosti tekst očistiti uz pomoć spaCy biblioteke (lematizacija, uklanjanje interpunkcije, brojeva i stop reči, pri čemu reč "not" treba zadržati). Izabrane numeričke kolone skalirati (npr. RobustScaler), a kategorijske kodirati (one-hot encoding). Sve tri transformacije objediniti u jedan `ColumnTransformer`.
- Podeliti podatke na trening i test skup u odnosu 80:20, tako da udeo klasa bude isti u oba skupa. Kreirati prvi klasifikacioni model primenom algoritma Logističke regresije, sa podrazumevanim vrednostima hiperparametara (dozvoljeno je samo povećati broj iteracija). Transformacije i model objediniti u jedan `Pipeline`.
- Napraviti predikcije primenom kreiranog modela nad test skupom i izračunati standardne evaluacione metrike (preciznost, odziv, F1) kako za svaku klasu pojedinačno, tako i sveukupno tj na nivou svih klasa. Prikazati matricu konfuzije. Interpretirati dobijene vrednosti metrika u kontekstu zadatka: koja klasa je najslabija i zašto, i koja je razlika između macro i weighted proseka.
- Kreirati drugi klasifikacioni model kroz postupak podešavanja hiperparametara. U komentaru navesti koje biste hiperparametre podešavali i na koji način tj koristeći koje opsege / liste vrednosti ako ne biste bili vremenski ograničeni. Zatim, izabrati dva hiperparametra, jedan za transformaciju teksta (TF-IDF), drugi za klasifikator, i izvršite podešavanje njihovih vrednosti kroz postupak (5-fold) kros-validacije, koristeći macro F1 kao metriku. Za svaki hiperparametar isprobati 2 do 3 vrednosti.
- Izvršiti predikcije primenom podešenog modela i izračunati standardne evaluacione metrike (preciznost, odziv, F1) kako za svaku klasu pojedinačno, tako i sveukupno tj na nivou svih klasa.
- Uporediti i prokomentarisati rezultate dobijene osnovnim i podešenim modelom, koristeći datu funkciju `get_model_metrics` (strana 2). Kao donju granicu u poređenje uključiti i model koji uvek predviđa najčešću klasu (DummyClassifier). Da li je podešavanje poboljšalo model, i posebno, da li je poboljšalo rezultat za najređu klasu?

---

[1] Podaci su preuzeti sa Kaggle-a, konkretno, sa ovog linka: https://www.kaggle.com/datasets/nicapotato/womens-ecommerce-clothing-reviews

Dati kod

Sledeću funkciju dobijate uz zadatak i možete je koristiti bez izmena:

```
def get_model_metrics(y_true: np.ndarray, y_pred: np.ndarray, model_name: str):
    report = metrics.classification_report(y_true, y_pred, output_dict=True)
    macro_avg = report['macro avg']
    weighted_avg = report['weighted avg']
    return {
        'Model': model_name,
        'Macro Precision': macro_avg['precision'],
        'Macro Recall': macro_avg['recall'],
        'Macro F1-Score': macro_avg['f1-score'],
        'Weighted Precision': weighted_avg['precision'],
        'Weighted Recall': weighted_avg['recall'],
        'Weighted F1-Score': weighted_avg['f1-score'],
        'Balanced Accuracy': metrics.balanced_accuracy_score(y_true, y_pred)
    }
```

Primer koda za grafik raspodele numeričke kolone po klasama:

```
plt.figure(figsize=(10, 6))
sb.kdeplot(data=data, x='Age', hue='sentiment',
           fill=True, common_norm=False, alpha=0.5, linewidth=2)
plt.title('Distribucija starosti po sentimentu')
plt.grid(True, linestyle='--', alpha=0.7)
plt.show()
```

Napomene za izradu

- Rešenje predati kao Jupyter svesku (.ipynb). Svaki korak zadatka započeti markdown ćelijom sa kratkim opisom, a tumačenja i obrazloženja pisati u markdown ćelijama, ne samo u komentarima koda.
- Imena kolona sadrže razmake (npr. *Review Text*), pa im se pristupa isključivo sa `data['Review Text']`.
- Kada ColumnTransformer sadrži više transformacija, ulaz u Pipeline mora biti DataFrame sa svim izabranim kolonama, a ne samo jedna kolona teksta.
- Ime hiperparametra u mreži za podešavanje sastoji se od imena koraka razdvojenih sa dve donje crte (korak u Pipeline-u, pa korak u ColumnTransformer-u, pa ime hiperparametra).
- Podešavanje hiperparametara raditi isključivo nad trening skupom; test skup koristiti samo za konačnu ocenu.
- Podešavanje sa 6 kombinacija i 5 foldova traje nekoliko minuta. Ne povećavati mrežu preko 9 kombinacija.
- Brojevi sami po sebi nisu dovoljni: svaka metrika treba da bude protumačena u kontekstu komentara kupaca.