Vežba: zadatak klasterizacije teksta (SBERT, hijerarhijska klasterizacija)

U fajlu “bbc-news-data.csv”[1] su dati novinski članci BBC-ja objavljeni u periodu 2004–2005. Svaki red je jedan članak. Fajl sadrži sledeće kolone (varijable):

- *category* - rubrika u kojoj je članak objavljen (business, entertainment, politics, sport, tech)
- *filename* - ime originalnog tekstualnog fajla iz kog je članak preuzet
- *title* - naslov članka
- *content* - tekst članka

Fajl je razdvojen tabom, a ne zarezom, pa se učitava sa `pd.read_csv(..., sep='	')`. Zbog vremena izvršavanja, sve korake raditi nad slučajnim uzorkom od 1500 članaka (`random_state=1`).

Cilj je da se članci grupišu isključivo na osnovu teksta, bez korišćenja kolone *category*. Ta kolona se koristi samo u poslednjem koraku, za proveru dobijenih klastera.

Koristeći opisane podatke iz navedenog fajla, potrebno je uraditi sledeće:

- Učitati podatke i ispitati ih (tipovi kolona, nedostajuće vrednosti, duplikati). Izbaciti redove kod kojih nedostaje tekst članka. Kreirati novu kolonu *article_text* koja objedinjuje naslov i tekst članka (kroz obično nadovezivanje stringova, sa tačkom i razmakom između njih).
- Ispitati dužinu članaka izraženu brojem reči: prikazati deskriptivnu statistiku i histogram. Na osnovu toga, i imajući u vidu ograničenje dužine ulaza SBERT modela, odlučiti na koliko prvih reči će se članci skratiti, i kreirati kolonu *article_text_reduced*. Ukratko obrazložiti izbor.
- Transformisati skraćene članke u vektore primenom SBERT modela *all-MiniLM-L12-v2*, koji se učitava lokalno iz foldera *models* (videti napomene). Prikazati dimenzije dobijene matrice i ukratko objasniti zašto se SBERT-u daje tekst bez prethodnog čišćenja (lematizacije, stop reči).
- Izračunati matricu kosinusnih distanci između članaka i nad njom primeniti hijerarhijsku (aglomerativnu) klasterizaciju Ward metodom. Prikazati dendrogram.
- Odrediti broj klastera. Odluku zasnovati na dendrogramu i na silhouette skoru za broj klastera od 2 do 8. Ukratko prokomentarisati da li se dendrogram i silhouette slažu, i obrazložiti konačan izbor. Dodeliti svakom članku oznaku klastera (kolona *clust*) i prikazati veličinu svakog klastera.
- Za svaki klaster odrediti 10 ključnih reči: tekst članaka u klasteru očistiti uz pomoć spaCy biblioteke (lematizacija, uklanjanje interpunkcije, brojeva i stop reči), izračunati TF-IDF i uzeti reči sa najvećom prosečnom TF-IDF vrednošću. Ključne

reči prikazati grafički (horizontalni bar plot za svaki klaster).

- Na osnovu ključnih reči i nekoliko naslova iz svakog klastera, dati svakom klasteru kratko ime (temu). Prokomentarisati da li su klasteri jasno razdvojeni i da li neki klaster deluje kao mešavina tema.
- Tek sada uporediti dobijene klastere sa kolonom *category* pomoću tabele `pd.crosstab`. Da li se klasteri poklapaju sa rubrikama? Ako se neka rubrika podelila na više klastera, ili su se dve rubrike spojile u jedan klaster, objasniti zašto bi se to moglo desiti na osnovu ključnih reči.

---

[1] Podaci su preuzeti sa Kaggle-a, konkretno, sa ovog linka: https://www.kaggle.com/datasets/hgultekin/bbcnewsarchive

Dati kod

Primer koda za dendrogram (`ward_linkage` je rezultat funkcije `sch.linkage`):

```
plt.figure(figsize=(12, 6))
sch.dendrogram(ward_linkage, truncate_mode='lastp', p=30)
plt.title('Dendrogram (Ward)')
plt.xlabel('Clanci')
plt.ylabel('Distanca')
plt.show()
```

Primer koda za prikaz ključnih reči po klasterima (funkciju `get_cluster_keywords(cluster_id)`, koja vraća `pd.Series` reč → prosečna TF-IDF vrednost, pišete sami):

```
n_clust = data['clust'].nunique()
fig, axes = plt.subplots(2, 3, figsize=(16, 9))
axes = axes.flatten()
for i in range(n_clust):
    kljucne = get_cluster_keywords(i + 1).sort_values()
    axes[i].barh(kljucne.index, kljucne.values, color='steelblue')
    axes[i].set_title(f'Klaster {i + 1}')
for ax in axes[n_clust:]:
    ax.remove()
plt.tight_layout()
plt.show()
```

Napomene za izradu

- Rešenje predati kao Jupyter svesku (.ipynb). Svaki korak zadatka započeti markdown ćelijom sa kratkim opisom, a tumačenja i obrazloženja pisati u markdown ćelijama, ne samo u komentarima koda.
- SBERT model se ne preuzima sa interneta. Raspakovani model staviti u folder *models* pored sveske i učitati ga sa `SentenceTransformer('models/all-MiniLM-L12-v2', local_files_only=True)`.
- Kolonama se pristupa sa `data['ime_kolone']`.
- Kolona *category* se ne sme koristiti ni u jednom koraku pre poslednjeg; klasterizacija je učenje bez nadzora.
- Silhouette skor nad matricom distanci računa se sa `metric='precomputed'`; zbog grešaka zaokruživanja negativne distance pre toga postaviti na nulu.
- Za ključne reči TF-IDF se računa posebno za svaki klaster, nad tekstom članaka tog klastera.
- Računanje SBERT vektora za 1500 članaka traje nekoliko minuta; vektore izračunati jednom i ne ponavljati tu ćeliju bez potrebe.
- Brojevi sami po sebi nisu dovoljni: svaki klaster i svaki izbor treba da budu protumačeni u kontekstu novinskih članaka.