Vežba: zadatak klasterizacije teksta (spaCy vektori reči, hijerarhijska klasterizacija)

U fajlu “bbc_news.csv”[1] su date vesti koje je BBC objavljivao preko svog RSS kanala u periodu 2022–2024. Svaki red je jedna vest. Fajl sadrži sledeće kolone (varijable):

- **title** - naslov vesti
- **pubDate** - datum i vreme objave, kao tekst (npr. “Mon, 07 Mar 2022 08:01:56 GMT”)
- **guid** - jedinstveni identifikator vesti (link bez dodatnih parametara)
- **link** - link ka vesti na BBC sajtu
- **description** - kratak sažetak vesti (jedna do dve rečenice)

Raditi samo sa vestima objavljenim tokom 2023. godine. Zbog vremena izvršavanja, nakon čišćenja (videti prvi korak) sve dalje korake raditi nad slučajnim uzorkom od 1500 vesti (random_state=1).

Cilj je da se vesti grupišu isključivo na osnovu teksta. Rubrika vesti (npr. sport, world, business), koja se može izvući iz linka, koristi se samo u poslednjem koraku, za proveru dobijenih klastera.

Koristeći opisane podatke iz navedenog fajla, potrebno je uraditi sledeće:

- Učitati podatke i ispitati ih (tipovi kolona, nedostajuće vrednosti, duplikati). Kolonu pubDate pretvoriti u datum (pd.to_datetime), prikazati broj vesti po godinama i zadržati samo vesti iz 2023. Izbaciti duplikate po naslovu (ista vest se u RSS kanalu pojavljuje više puta) i prokomentarisati koliko ih je bilo. Izbaciti stavke koje nisu tekstualne vesti, tj. one čiji link ne vodi ka delu sajta /news/ ili /sport/ (audio i video sadržaj, vremenska prognoza; videti dati kod). Tek nakon toga izdvojiti uzorak od 1500 vesti.
- Kreirati novu kolonu **news_text** koja objedinjuje sadržaj kolona title i description (kroz obično nadovezivanje stringova, sa tačkom i razmakom između njih). Ispitati dužinu tekstova izraženu brojem reči (deskriptivna statistika i histogram) i odlučiti da li je potrebno skraćivanje tekstova, kao u primeru sa Guardian člancima. Ukratko prokomentarisati šta kratki tekstovi znače za kvalitet vektora dokumenta koji se dobija usrednjavanjem vektora reči.
- Transformisati sadržaj kolone news_text u vektorsku (tj numeričku) reprezentaciju primenom pristupa zasnovanog na vektorima reči (word vectors), i konkretno vektorima reči raspoloživim u okviru spaCy medium modela (“en_core_web_md”). Pre računanja vektora tekst očistiti (lematizacija, uklanjanje interpunkcije, brojeva, URL-ova i stop reči), a transformaciju implementirati kao klasu koja nasleđuje BaseEstimator i TransformerMixin. Prikazati dimenzije dobijene matrice. Ukratko objasniti kako se od vektora reči dobija vektor cele vesti i zašto je ovde, za razliku od SBERT-a, uklanjanje stop reči korisno.
- Proveriti da li postoje vesti čiji je vektor nula-vektor (nijedna reč nije pronađena u rečniku modela) i, ako postoje, izbaciti ih uz kratko obrazloženje zašto bi one bile problem za kosinusnu sličnost.
- Izračunati matricu kosinusnih distanci između vesti i nad njom primeniti aglomerativno hijerarhijsko klasterovanje Ward metodom. Prikazati dendrogram.

- Odrediti optimalni broj klastera na osnovu dendrograma i siluet skora (silhouette score) za broj klastera od 2 do 8; siluet skorove prikazati bar plotom. Prokomentarisati da li se dendrogram i siluet skor slažu i obrazložiti izbor optimalnog broja klastera. Dodeliti svakoj vesti oznaku klastera (kolona clust) i prikazati veličinu svakog klastera.
- Za svaki od klastera odrediti top 10 reči / izraza (unigrami i bigrami) na osnovu TF-IDF metrike, računate posebno nad tekstovima svakog klastera. Ključne reči prikazati grafički (dati kod).
- Opisati svaki klaster na osnovu identifikovanih top 10 reči / izraza i uvida u 10 nasumično izabranih naslova iz klastera (random_state=1), i dati svakom klasteru kratko ime (temu). Prokomentarisati da li su klasteri jasno razdvojeni i da li neki klaster deluje kao mešavina tema.
- Tek sada izdvojiti rubriku iz linka (dati kod) i uporediti dobijene klastere sa rubrikama pomoću tabele pd.crosstab. Koja rubrika je najbolje izdvojena u poseban klaster, a koje se mešaju? Na osnovu ključnih reči objasniti zašto se, na primer, vesti iz rubrika uk i world teže razdvajaju nego sportske vesti.
- *Dodatno, ako ostane vremena:* za izabrani broj klastera ponoviti klasterovanje sa average metodom povezivanja (method='average') i uporediti siluet skor i veličine klastera sa Ward rešenjem. Koje rešenje je korisnije za opis tema i zašto?

[1] Podaci su preuzeti iz materijala sa vežbi (folder tm/data); fajl kopirati u folder data pored sveske. Originalni izvor: https://www.kaggle.com/datasets/gpreda/bbc-news

Dati kod

Pretvaranje datuma i izbacivanje stavki koje nisu tekstualne vesti (link mora da sadrži /news/ ili /sport/):

```
data['pubDate'] = pd.to_datetime(data['pubDate'], format='%a, %d %b %Y %H:%M:%S %Z')

delovi_linka = data['link'].str.extract(r'bbc\.co(?:\.uk|m)/(news|sport)/([a-z]+)')
data = data[delovi_linka[0].notna()]
```

Izdvajanje rubrike iz linka (koristiti tek u poslednjem koraku):

```
delovi_linka = data['link'].str.extract(r'bbc\.co(?:\.uk|m)/(news|sport)/([a-z]+)')
data['rubrika'] = np.where(delovi_linka[0] == 'sport', 'sport', delovi_linka[1])
GLAVNE_RUBRIKE = ['uk', 'world', 'sport', 'business', 'entertainment']
data['rubrika'] = data['rubrika'].where(data['rubrika'].isin(GLAVNE_RUBRIKE), 'ostalo')
```

Primer koda za prikaz ključnih reči po klasterima (funkciju extract_keywords_for_cluster(cluster_id), koja vraća listu parova (reč, prosečna TF-IDF vrednost), pišete sami):

```
n_clust = data['clust'].nunique()
fig, axes_grid = plt.subplots(nrows=2, ncols=4, figsize=(18, 9), constrained_layout=True)
axes = axes_grid.flatten()
for i in range(n_clust):
    scored_kwds = sorted(extract_keywords_for_cluster(i + 1), key=lambda item: item[1])
    axes[i].barh([kw for kw, s in scored_kwds], [s for kw, s in scored_kwds])
    axes[i].set_title(f'Klaster {i + 1}')
    axes[i].grid(visible=True, axis='y', color='gray', alpha=0.35)
for ax in axes[n_clust:]:
    ax.remove()
fig.suptitle('Kljucne reci za razlicite klastere BBC vesti')
plt.show()
```

Napomene za izradu

- Rešenje predati kao Jupyter svesku (.ipynb). Svaki korak zadatka započeti markdown ćelijom sa kratkim opisom, a tumačenja i obrazloženja pisati u markdown ćelijama, ne samo u komentarima koda.
- spaCy model se učitava sa spacy.load(“en_core_web_md”, disable=['parser', 'ner']); isključivanje parsera i prepoznavanja entiteta značajno ubrzava obradu. Vektori reči u ovom modelu imaju 300 dimenzija. Mali model (en_core_web_sm) nema prave vektore reči i ne sme se koristiti za ovaj zadatak.
- Kolonama se pristupa sa data['ime_kolone']. Nakon filtriranja i uzorkovanja pozvati reset_index(drop=True), da bi redni broj reda u DataFrame-u odgovarao redu u matrici vektora.
- Rubrika se ne sme koristiti ni u jednom koraku pre poslednjeg; klasterizacija je učenje bez nadzora.
- Siluet skor nad matricom distanci računa se sa metric='precomputed'; zbog grešaka zaokruživanja negativne distance pre toga postaviti na nulu (np.clip).
- Oznake klastera dobijene funkcijom sch.fcluster počinju od 1, a ne od 0.
- Brojevi sami po sebi nisu dovoljni: svaki klaster i svaki izbor treba da budu protumačeni u kontekstu novinskih vesti.